面向机器学习时代的动态交通分配

Dynamic traffic assignment in the machine learning era

葛乾
西南交通大学交通运输与物流学院
geqian@swjtu.edu.cn

2020.04.26@SWJTU

简介

- 关于我
  - 求学：东南大学土木工程学院（2006-2010），清华大学工业工程系(2010-2012)，东京工业大学土木与环境工学系博士（2012-2017)
  - 工作：东京工业大学博士后（2017-2019)，西南交通大学副教授(2019-)
  - 研究方向：动态交通分配，交通网络优化
- 关于今天的交流
  - 动态交通分配？
  - 机器学习？
  - 机器学习如何影响动态交通分配？
  - * 动态网络加载模型
- 关于听众
  - 应该对静态用户均衡模型有一定理解（Wardrop 均衡，Beckmann 模型，MSA 算法等）

静态与动态用户均衡理论基础

基于代理模型的动态用户均衡问题

基于宏观基本图的交通流仿真

其他课题

静态用户均衡

- Wardrop 均衡准则："All routes used by travelers leaving the same origin for the same destination have equal and minimal travel time.."(对于 OD 相同的出行者，所有被利用的路径的旅行时间应相等且最小)
- 建模：Beckmann 模型为例 $\min z(\boldsymbol{x}) = \sum_a \int_0^{x_a} t_a(w)\mathrm{d}w$ s.t.$\sum_k f_k^{rs} = q_{rs}\ \forall r, s;\ f_k^{rs} \geqslant 0\ \forall k, r, s$
- 求解：MSA 算法为例
  - 第 0 步：使用自由流速度 $\{t_a^0\}$ 初始化，寻找各个 OD 对的最小成本路径，执行全有全无分配，计算路径流量 $\{x_a^1\}$，记数为 $n = 1$；
  - 第 1 步：更新路段旅行时间，$t_a^n = t_a(x_a^n)\ \forall a$；
  - 第 2 步：更新各个 OD 对的最小成本路径，执行全有全无分配，计算路径流量 $\{y_a^n\}$；
  - 第 3 步：更新流量，各路段新的流量为 $x_a^{n+1} = x_a^n + \frac{1}{n}(y_a^n - x_a^n)$；
  - 第 4 步：收敛判定。若收敛，则停止；不收敛，回归到第 1 步

静态用户均衡（续）

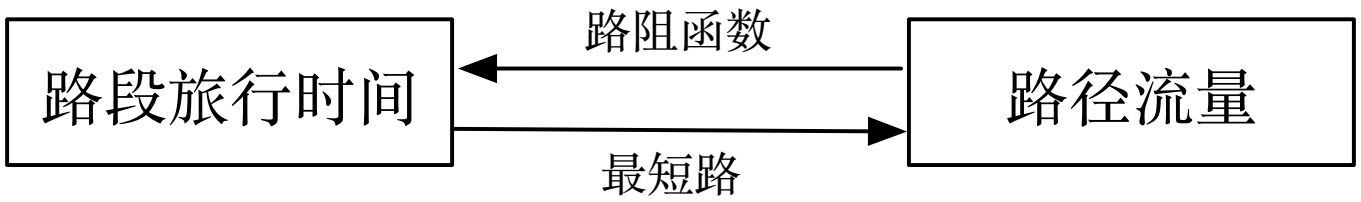

为什么需要动态用户均衡模型？

- 静态用户均衡模型中，使用非减的路阻函数 (link performance function) 表示拥挤程度。例如线性函数，BPR 函数等
- 路阻函数有何缺陷？
  - 路段中并非所有车辆经历相同程度的拥堵。道路中车辆各向异质 (anisotropic) 且先后影响 (causality)
  - 什么是流量？交通波如何传递？
  - 是否考虑排队溢出 (queue spillback) 现象？
- 为了更真实地刻画道路拥挤程度，需要基于交通流理论的拥堵模型

为什么需要动态用户均衡模型？

- 静态用户均衡模型中，使用非减的路阻函数 (link performance function) 表示拥挤程度。例如线性函数，BPR 函数等
- 路阻函数有何缺陷？
  - 路段中并非所有车辆经历相同程度的拥堵。道路中车辆各向异质 (anisotropic) 且先后影响 (causality)
  - 什么是流量？交通波如何传递？
  - 是否考虑排队溢出 (queue spillback) 现象？
- 为了更真实地刻画道路拥挤程度，需要基于交通流理论的拥堵模型

为什么需要动态用户均衡模型？

- 静态用户均衡模型中，使用非减的路阻函数 (link performance function) 表示拥挤程度。例如线性函数，BPR 函数等
- 路阻函数有何缺陷？
  - 路段中并非所有车辆经历相同程度的拥堵。道路中车辆各向异质 (anisotropic) 且先后影响 (causality)
  - 什么是流量？交通波如何传递？
  - 是否考虑排队溢出 (queue spillback) 现象？
- 为了更真实地刻画道路拥挤程度，需要基于交通流理论的拥堵模型

动态用户均衡

- 均衡准则："All routes used by travelers leaving the same origin **at the same time** for the same destination have equal and minimal travel time.."(对于 OD 相同**且出发时间相同**的出行者，所有被利用的路径的旅行时间应相等且最小)
- 建模：非线性互补模型，变分不等式等
- 求解：MSA 算法，投影方法等

动态用户均衡（续）

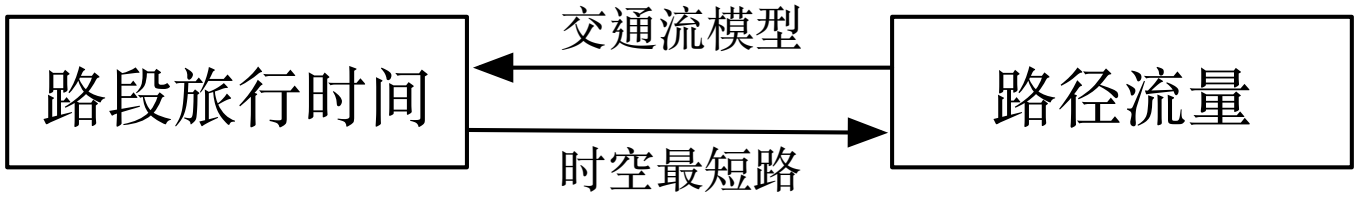

- 构成部分：
  - 路径选择准则的**数学描述** → 互补条件
  - **路径延误算子** (path delay operator)→ 交通流模型
- 变体：
  - 连续出发时间（Friesz et al., 1989; Ban et al., 2012) vs 离散出发时间（Wie et al., 1995; Akamatsu, 2001）?
  - 仅考虑路径选择（Wie et al., 1995; Akamatsu, 2001) vs 同时考虑路径和出发时间选择（Nie and Zhang, 2007)

DUE 的求解框架

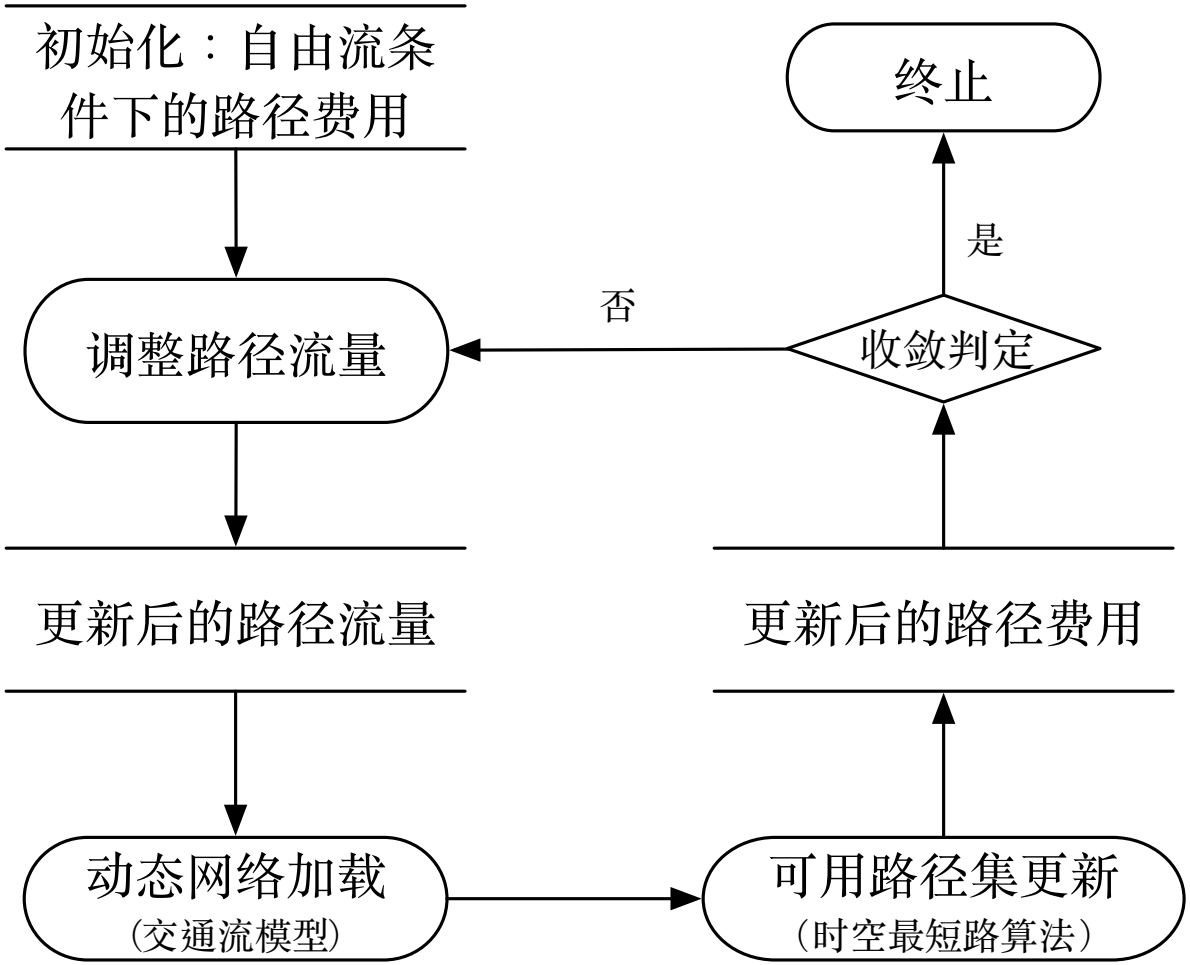
初始化：自由流条件下的路径费用
调整路径流量
更新后的路径流量
动态网络加载
(交通流模型)
可用路径集更新
(时空最短路算法)
更新后的路径费用
收敛判定
否
是
终止

DUE 问题的数学描述

- 离散 DUE 用非线性互补问题描述为：

$$\begin{cases} f_p^{rs}(t)[c_p^{rs}(t) - \tilde{c}_p^{rs}(t)] = 0 \ \forall r, s, t, p \\ c_p^{rs}(t) - \tilde{c}_p^{rs}(t) \geqslant 0 \ \forall r, s, t, p \\ f_p^{rs}(t) \geqslant 0 \ \forall r, s, t, p \\ \sum_p f_p^{rs}(t) = v_t^{rs} \ \forall r, s, t \end{cases}$$

- 等价的变分不等式问题为 (Wie et al. 1995):

$$\begin{cases} \sum_r \sum_s \sum_p \sum_t c(\tilde{f}_p^{rs}(t))[f_p^{rs}(t) - \tilde{f}_p^{rs}(t)] \geqslant 0 \ \forall f_p^{rs}(t) \in \Omega \\ \Omega : \{f_p^{rs}(t) \in R^+ | \sum_p f_p^{rs}(t) = v_t^{rs} \forall r, s, t\} \end{cases}$$

r, s, p, t 分别为起点，终点，路径和分配时段；$\tilde{f}_p^{rs}(t)$ 为从起点 r 到终点 s 出发时间为 t 的 OD 需求中，在均衡条件下使用路径 p 的流量；$c(\tilde{f}_p^{rs}(t))$ 为路径延误算子, $f_p^{rs}(t)$ 为非均衡条件下的路径流量，v_t^{rs} 为起讫点是 $r-s$ 出发时间为 t 的 OD 需求。

路径延误算子

- 从路径流量到路径费用的映射 → 宏观交通流模型
  - M-N 模型 (Merchant and Nemhauser,1978a,b)
  - 路段延误模型 (link delay model) (Friesz *et al.*,1993);
  - 点排队模型 (Point-queue model) (Vickrey, 1969; Ban *et al.*, 2012; Han *et al.*, 2013a,b);
  - LWR 模型 (Lighthill and Whitham, 1955;Richards, 1956);
  - 元胞传输模型 (Daganzo, 1994; Daganzo, 1995)
  - 路段传输模型 (Yperman *et al.*, 2006; Jin, 2015)
  - 基于宏观基本图的模型 (Yildirimoglu and Geroliminis, 2014; Leclercq *et al.*, 2015; Ge and Fukuda, 2019)
- 限制？(Song *et al.*, 2017):
  - 计算较复杂
  - 缺少解析特征：存在性？唯一性？收敛保证？
  - 不可导

路径延误算子

- 从路径流量到路径费用的映射 → 宏观交通流模型
  - M-N 模型 (Merchant and Nemhauser,1978a,b)
  - 路段延误模型 (link delay model) (Friesz *et al.*,1993);
  - 点排队模型 (Point-queue model) (Vickrey, 1969; Ban *et al.*, 2012; Han *et al.*, 2013a,b);
  - LWR 模型 (Lighthill and Whitham, 1955;Richards, 1956);
  - 元胞传输模型 (Daganzo, 1994; Daganzo, 1995)
  - 路段传输模型 (Yperman *et al.*, 2006; Jin, 2015)
  - 基于宏观基本图的模型 (Yildirimoglu and Geroliminis, 2014; Leclercq *et al.*, 2015; Ge and Fukuda, 2019)
- 限制？(Song *et al.*, 2017):
  - 计算较复杂
  - 缺少解析特征：存在性？唯一性？收敛保证？
  - 不可导

可能的解决方案

- 计算复杂问题 → 代理模型（+ 基于宏观基本图的交通流模型）
- 缺少解析性问题 → 代理模型
- 不可导 → 代理模型

代理模型

- 从输入的决策变量到输出的仿真结果的响应曲面的回归模型 (Hussain *et al.*, 2002; Queipo *et al.*, 2005; Jakobsson *et al.*, 2010; Chen *et al.*, 2013).
- 回归的工具库:
  - 线性/多项式回归 (Osorio and Bierlaire, 2013)
  - 神经网络
  - 克里金法 (高斯过程回归) (Song *et al.*, 2017)
  - 支持向量回归 (Chen *et al.*, 2013)
  - 等等
- 从机器学习的第一节课得到的启示：No free lunch（没有最好的模型，只有适合的场景）

代理模型

- 从输入的决策变量到输出的仿真结果的响应曲面的回归模型 (Hussain *et al.*, 2002; Queipo *et al.*, 2005; Jakobsson *et al.*, 2010; Chen *et al.*, 2013).
- 回归的工具库:
  - 线性/多项式回归 (Osorio and Bierlaire, 2013)
  - 神经网络
  - 克里金法 (高斯过程回归) (Song *et al.*, 2017)
  - 支持向量回归 (Chen *et al.*, 2013)
  - 等等
- 从机器学习的第一节课得到的启示：No free lunch（没有最好的模型，只有适合的场景）

带权重的核岭回归

Table: 几种代理模型的比较

模型	损失函数	预测
LR	$\sum_{c=1}^{n_c}(\beta^{rspt\,T}\mathbf{f_c}-\phi_c^{rspt})^2$	$\phi^{rspt}=\boldsymbol{\phi}^{rspt\,T}(\mathbf{F}\mathbf{F}^T)^{-1}\mathbf{F}\mathbf{f}$
RR	$\sum_{c=1}^{n_c}(\beta^T\mathbf{f_c}-\phi_c^{rspt})^2+\frac{1}{2}\lambda\lvert\lvert\beta^{rspt}\rvert\rvert^2$	$\phi^{rspt}=\boldsymbol{\phi}^{rspt\,T}(\mathbf{F}\mathbf{F}^T+\lambda\mathbf{I})^{-1}\mathbf{F}\mathbf{f}$
WRR	$\sum_{c=1}^{n_c}w_c(\beta^{rspt\,T}\mathbf{f_c}-\phi_c^{rspt})^2+\frac{1}{2}\lambda\lvert\lvert\beta^{rspt}\rvert\rvert^2$	$\phi^{rspt}=\boldsymbol{\phi}^{rspt\,T}(\mathbf{W}\mathbf{F}\mathbf{F}^{\mathbf{T}}+\lambda\mathbf{I})^{-1}\mathbf{W}\mathbf{F}\mathbf{f}$
WKRR	同上	$\phi^{rspt}=\boldsymbol{\phi}^{rspt\,T}(\mathbf{W}\mathbf{K}+\lambda\mathbf{I})^{-1}\mathbf{W}k(\mathbf{f},\cdot)$

WKRR 的优点：

- 有闭解
- 引入正则项 (regularization) 避免了回归问题的不适定性 (ill-poseness)
- 通过核方法以较低计算成本把线性关系映射到高维

带权重的核岭回归

Table: 几种代理模型的比较

模型	损失函数	预测
LR	$\sum_{c=1}^{n_c}(\beta^{rspt\,T}\mathbf{f_c}-\phi_c^{rspt})^2$	$\phi^{rspt}=\boldsymbol{\phi}^{rspt\,T}(\mathbf{F}\mathbf{F}^T)^{-1}\mathbf{F}\mathbf{f}$
RR	$\sum_{c=1}^{n_c}(\beta^T\mathbf{f_c}-\phi_c^{rspt})^2+\frac{1}{2}\lambda\lVert\beta^{rspt}\rVert^2$	$\phi^{rspt}=\boldsymbol{\phi}^{rspt\,T}(\mathbf{F}\mathbf{F}^T+\lambda\mathbf{I})^{-1}\mathbf{F}\mathbf{f}$
WRR	$\sum_{c=1}^{n_c}w_c(\beta^{rspt\,T}\mathbf{f_c}-\phi_c^{rspt})^2+\frac{1}{2}\lambda\lVert\beta^{rspt}\rVert^2$	$\phi^{rspt}=\boldsymbol{\phi}^{rspt\,T}(\mathbf{W}\mathbf{F}\mathbf{F}^{\mathbf{T}}+\lambda\mathbf{I})^{-1}\mathbf{W}\mathbf{F}\mathbf{f}$
WKRR	同上	$\phi^{rspt}=\boldsymbol{\phi}^{rspt\,T}(\mathbf{W}\mathbf{K}+\lambda\mathbf{I})^{-1}\mathbf{W}k(\mathbf{f},\cdot)$

WKRR 的优点：

- 有闭解
- 引入正则项 (regularization) 避免了回归问题的不适定性 (ill-poseness)
- 通过核方法以较低计算成本把线性关系映射到高维

核方法

当核矩阵 $K := \{k(\mathbf{f}, \mathbf{f}')\}$ 正定时，称其为 Mercer 核 (Haykin, 2009). 对满足 $\int_a^b g^2(\mathbf{f})d\mathbf{f} \leqslant \infty$ 的所有 $\mathbf{g}(\cdot)$，$\int_a^b \int_a^b g(\mathbf{f})g(\mathbf{f}')k(\mathbf{f}, \mathbf{f}')d\mathbf{f}d\mathbf{f}' \geqslant 0,\ \mathbf{f}, \mathbf{f}' \in \mathcal{F}$ 成立。

在 R^n 中常见的 Mercer 核有:

- 线性核: $k(\mathbf{f}, \mathbf{f}') = \mathbf{f}^T\mathbf{f}$,
- 多项式核: $k(\mathbf{f}, \mathbf{f}') = (\mathbf{f}^T\mathbf{f}' + r)^d,\ r \geqslant 0$, and
- RBF 核: $k(\mathbf{f}, \mathbf{f}') = e^{-\frac{||\mathbf{f}-\mathbf{f}'||^2}{2\delta^2}},\ \delta > 0$.

基于代理模型的 DUE 问题

- 一阶段模型

$$\begin{cases} \text{寻找}\tilde{\mathbf{f}} \in \Omega \text{ 使得} \langle \hat{\phi}(\tilde{\mathbf{f}}), \mathbf{f} - \tilde{\mathbf{f}} \rangle \geqslant 0, \ \forall \mathbf{f} \in \Omega \\ \Omega : \{\mathbf{f} \in R^{(n_p \times n_t)+} | \mathbf{M}\mathbf{f} = \boldsymbol{v}\} \end{cases}$$

- 问题?
- 两阶段模型 (带自适应抽样)
  - 上层模型

$$\arg\min_{\beta_k^{rspt}} \sum_{c=1}^{n_k} w_k^{rspt} (\beta_k^{rspt\,T} \mathbf{f_c} - \phi_p^{rspt})^2 + \frac{1}{2}\lambda ||\beta_k^{rspt}||^2 \ \forall r, s, p, t$$

  - 下层模型

$$\begin{cases} \text{寻找}\tilde{\mathbf{f}} \in \Omega \text{ 使得} \langle \hat{\phi}_k(\tilde{\mathbf{f}}), \mathbf{f} - \tilde{\mathbf{f}} \rangle \geqslant 0, \ \forall \mathbf{f} \in \Omega \\ \Omega : \{\mathbf{f} \in R^{(n_p \times n_t)+} | \mathbf{M}\mathbf{f} = \boldsymbol{v}\} \end{cases}$$

基于代理模型的 DUE 问题

- 一阶段模型

$$\begin{cases} \text{寻找}\tilde{\mathbf{f}} \in \Omega \text{ 使得} \langle \hat{\phi}(\tilde{\mathbf{f}}), \mathbf{f} - \tilde{\mathbf{f}} \rangle \geqslant 0, \ \forall \mathbf{f} \in \Omega \\ \Omega : \{\mathbf{f} \in R^{(n_p \times n_t)+} | \mathbf{M}\mathbf{f} = \boldsymbol{v}\} \end{cases}$$

- 问题?
- 两阶段模型 (带自适应抽样)
  - 上层模型

$$\arg\min_{\beta_k^{rspt}} \sum_{c=1}^{n_k} w_k^{rspt} (\beta_k^{rspt\,T} \mathbf{f_c} - \phi_p^{rspt})^2 + \frac{1}{2}\lambda ||\beta_k^{rspt}||^2 \ \forall r, s, p, t$$

  - 下层模型

$$\begin{cases} \text{寻找}\tilde{\mathbf{f}} \in \Omega \text{ 使得} \langle \hat{\phi}_k(\tilde{\mathbf{f}}), \mathbf{f} - \tilde{\mathbf{f}} \rangle \geqslant 0, \ \forall \mathbf{f} \in \Omega \\ \Omega : \{\mathbf{f} \in R^{(n_p \times n_t)+} | \mathbf{M}\mathbf{f} = \boldsymbol{v}\} \end{cases}$$

基于代理模型的 DUE 问题

- 一阶段模型

$$\begin{cases} \text{寻找}\tilde{\mathbf{f}} \in \Omega \text{ 使得} \langle \hat{\phi}(\tilde{\mathbf{f}}), \mathbf{f} - \tilde{\mathbf{f}} \rangle \geqslant 0, \ \forall \mathbf{f} \in \Omega \\ \Omega : \{\mathbf{f} \in R^{(n_p \times n_t)+} | \mathbf{M}\mathbf{f} = \boldsymbol{v}\} \end{cases}$$

- 问题?
- 两阶段模型 (带自适应抽样)
  - 上层模型

$$\arg\min_{\beta_k^{rspt}} \sum_{c=1}^{n_k} w_k^{rspt} (\beta_k^{rspt\,T} \mathbf{f_c} - \phi_p^{rspt})^2 + \frac{1}{2}\lambda ||\beta_k^{rspt}||^2 \ \forall r, s, p, t$$

  - 下层模型

$$\begin{cases} \text{寻找}\tilde{\mathbf{f}} \in \Omega \text{ 使得} \langle \hat{\phi}_k(\tilde{\mathbf{f}}), \mathbf{f} - \tilde{\mathbf{f}} \rangle \geqslant 0, \ \forall \mathbf{f} \in \Omega \\ \Omega : \{\mathbf{f} \in R^{(n_p \times n_t)+} | \mathbf{M}\mathbf{f} = \boldsymbol{v}\} \end{cases}$$

求解框架

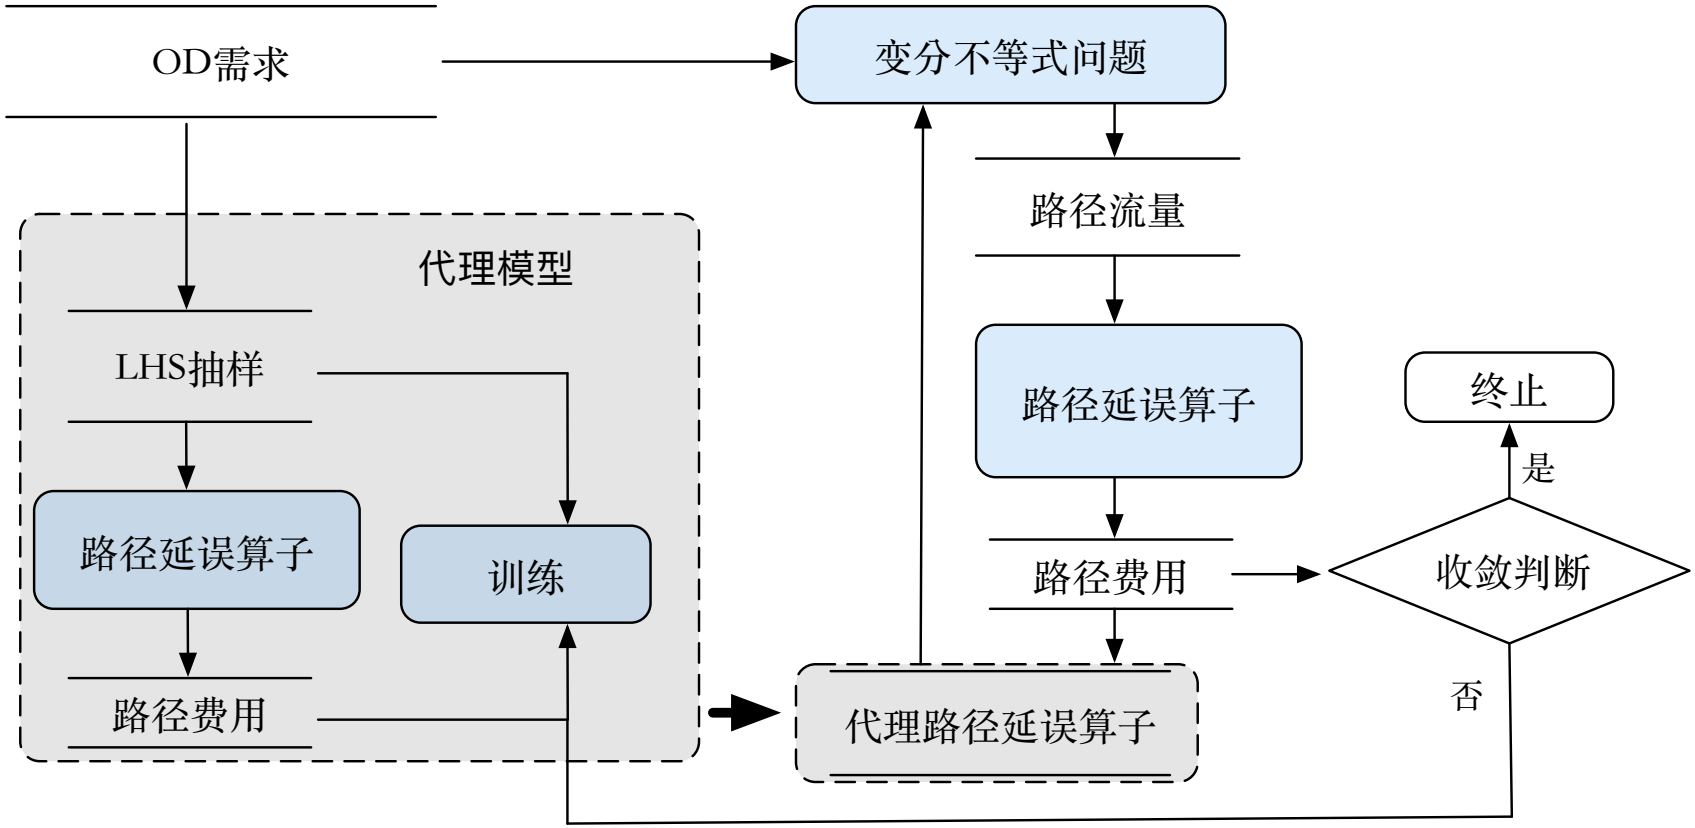
OD需求
变分不等式问题
路径流量
代理模型
LHS抽样
路径延误算子
训练
路径费用
路径延误算子
路径费用
收敛判断
是
终止
否
代理路径延误算子

上层问题求解算法

Algorithm 1: Revised iterative update algorithm

$k \leftarrow 0$; Sample path flows from Ω, get path cost $\phi(\hat{\boldsymbol{f}})$ from the DNL module, and fit the WKRR;
while $||\hat{\phi}(\boldsymbol{f_k}) - \phi(\boldsymbol{f_k})||_p \geqslant \delta$ **do**
  Update the kernel matrix K_k
  for *each assignment interval* t **do**
    Update the weights w_k^{rspt} by the new data $\boldsymbol{f_k}$ and the samples in previous iterati
    Update the kernel operator on each path with the new data
    Update the inverse matrix $(\boldsymbol{WK} + \lambda \boldsymbol{I})^{-1}$ for each assignment interval
    Save all calculated matrices and arrays in memory
  end
  Solve the [VI-SADUE] to get $\boldsymbol{f_{k+1}}$ by Algorithm 2;
  Calculate the surrogate path cost $\hat{\phi}(\boldsymbol{f_k})$ and exact path cost $\phi(\boldsymbol{f_k})$;
  Set $k : k + 1$
end

下层问题求解算法

Algorithm 2: Customized extragradient algorithm

$l \leftarrow 0$; Initialize the path flow $\mathbf{f_0} = \mathbf{f_k} + \varepsilon_k/k$ where ε is a vector of white noise draw from Gaussian distribution $\mathcal{N}(0,1)$;

while $||\widehat{\mathbf{f}}_{\mathbf{l+1}} - \widehat{\mathbf{f}}_{\mathbf{l}}||_p \geqslant \epsilon$ **do**

  Determine the step size α_l by try-and trail;

  Get a tentative point of path flow:

  $$\widehat{\mathbf{f}}_{\mathbf{l}} = P_\Omega[\mathbf{f_l} - \alpha_l \phi_k^{rspt\,T}(\mathbf{W_k K_k} + \lambda \mathbf{I})^{-1}\mathbf{W_k} k(\mathbf{f}, \cdot)];$$

  Get the path flow:

  $$\widehat{\mathbf{f}}_{\mathbf{l+1}} = P_\Omega[\mathbf{f_l} - \alpha_l \phi_k^{rspt\,T}(\mathbf{W_k K_k} + \lambda \mathbf{I})^{-1}\mathbf{W_k} k(\widehat{\mathbf{f}}_{\mathbf{l}}, \cdot)]$$

  Set $l := l + 1$

end

实验结果

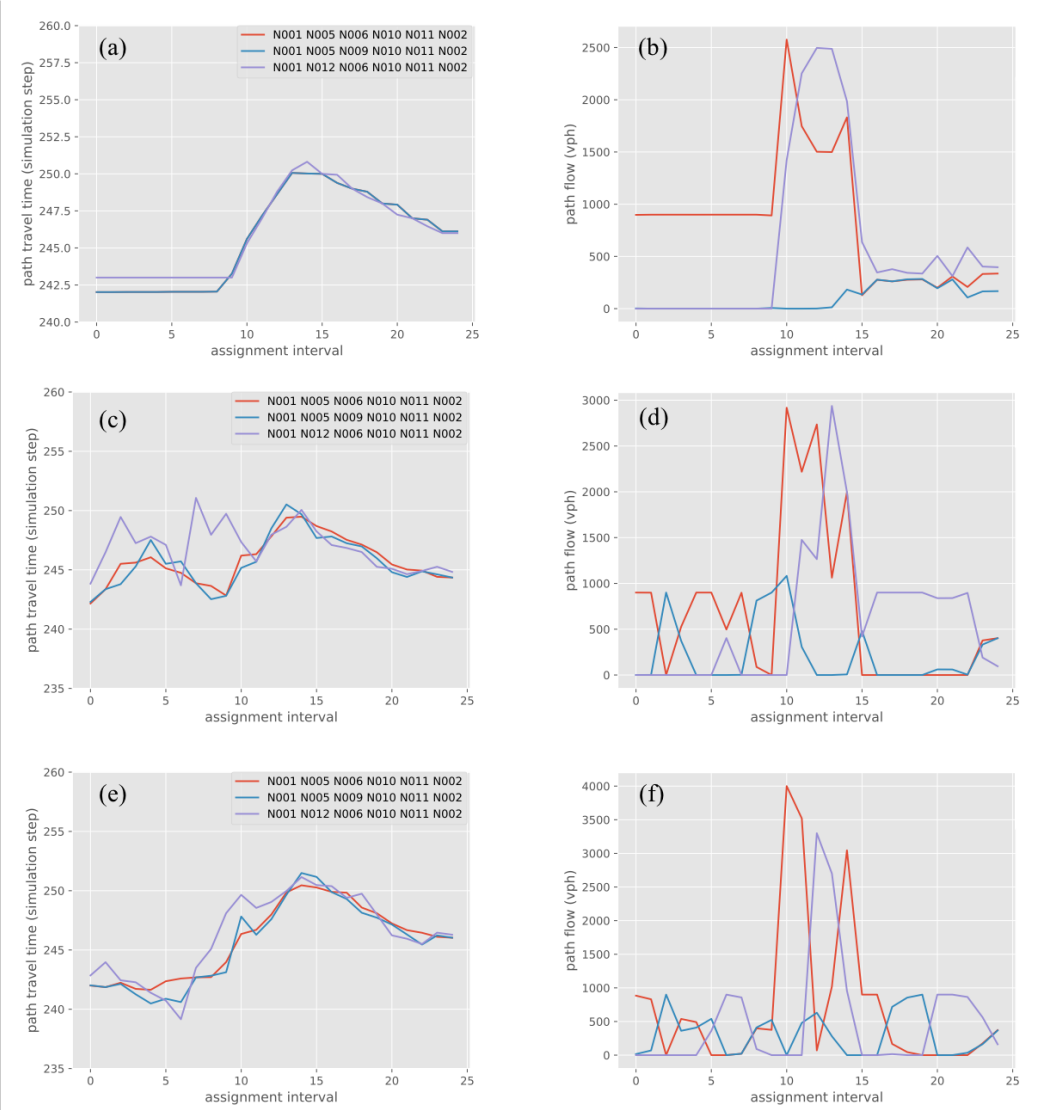
(a)
(b)
(c)
(d)
(e)
(f)
N001 N005 N006 N010 N011 N002
N001 N005 N009 N010 N011 N002
N001 N012 N006 N010 N011 N002
path travel time (simulation step)
path flow (vph)
assignment interval

实验结果 (续)

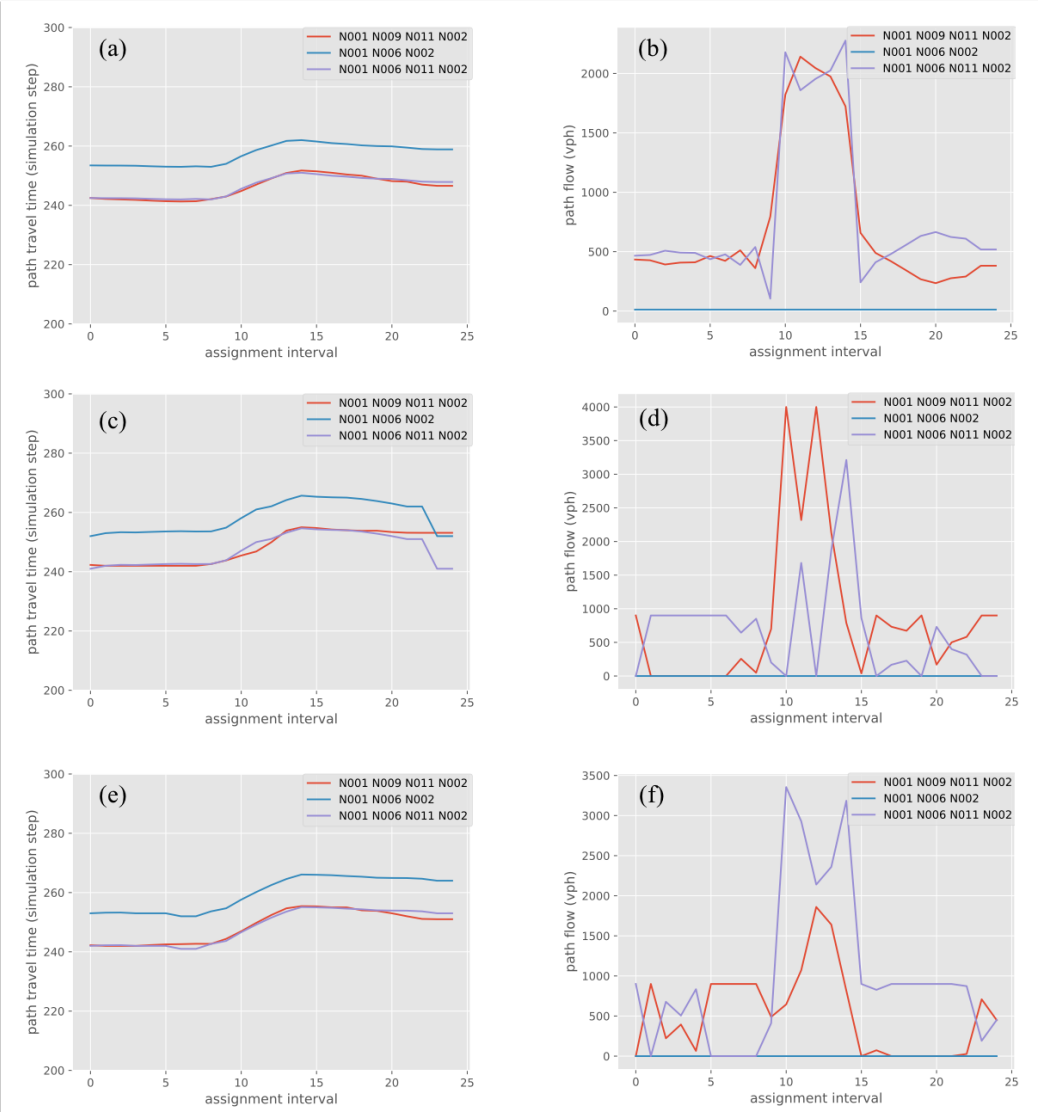
(a)
(b)
(c)
(d)
(e)
(f)
N001 N009 N011 N002
N001 N006 N002
N001 N006 N011 N002
path travel time (simulation step)
path flow (vph)
assignment interval

本节讨论

- 机器学习正在改变我们对交通领域中很多传统问题的认识
- 机器学习方法并不（一定）能代替物理模型，更好的解决方案是把物理模型和基于数据的模型结合 (Carolina Osorio)
- 未来的拓展: 动态系统最优问题？逆问题？交通网络设计问题?

更多细节：**Qian Ge**, Daisuke Fukuda, Ke Han and Wenjing Song. Reservoir-based surrogate modeling of dynamic user equilibrium. Transportation Research Part C: Emerging Technologies, 113(2020): 350-369.

动态网络加载

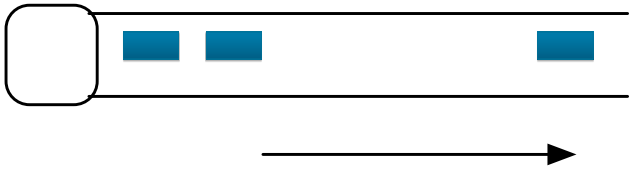

link model

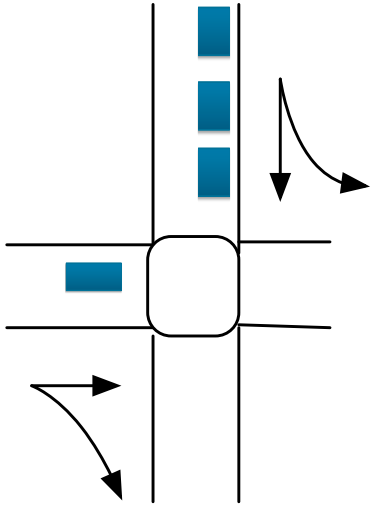

node model

- 动态网络加载为从不同出发时间的路径流量到路径费用的映射

$$\mathbf{f} \rightarrow \mathbf{c}$$

- 车辆在路段和交叉口的运行规律分别由线模型（link model）和节点模型（node model）描述

宏观基本图

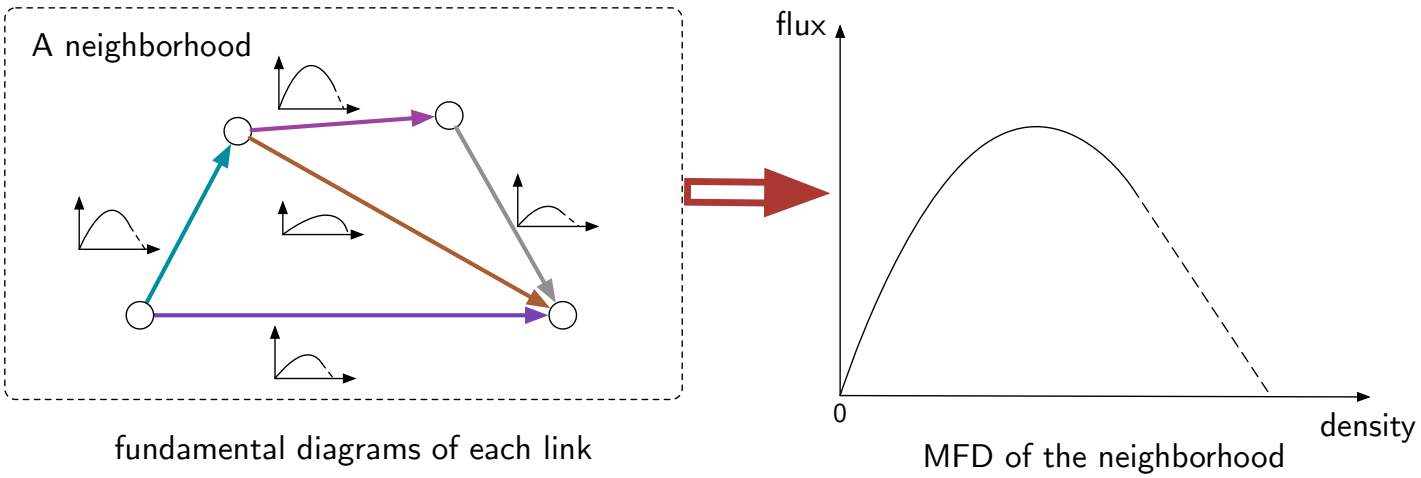

Figure: MFD

路段中密度和流量的关系可以用基本图 (fundamental diagram) 表示。在邻域中，车辆的累积量和边缘流量遵循相似的关系，被称之宏观基本图 (Daganzo, 2007; Geroliminis and Daganzo, 2008)

邻域

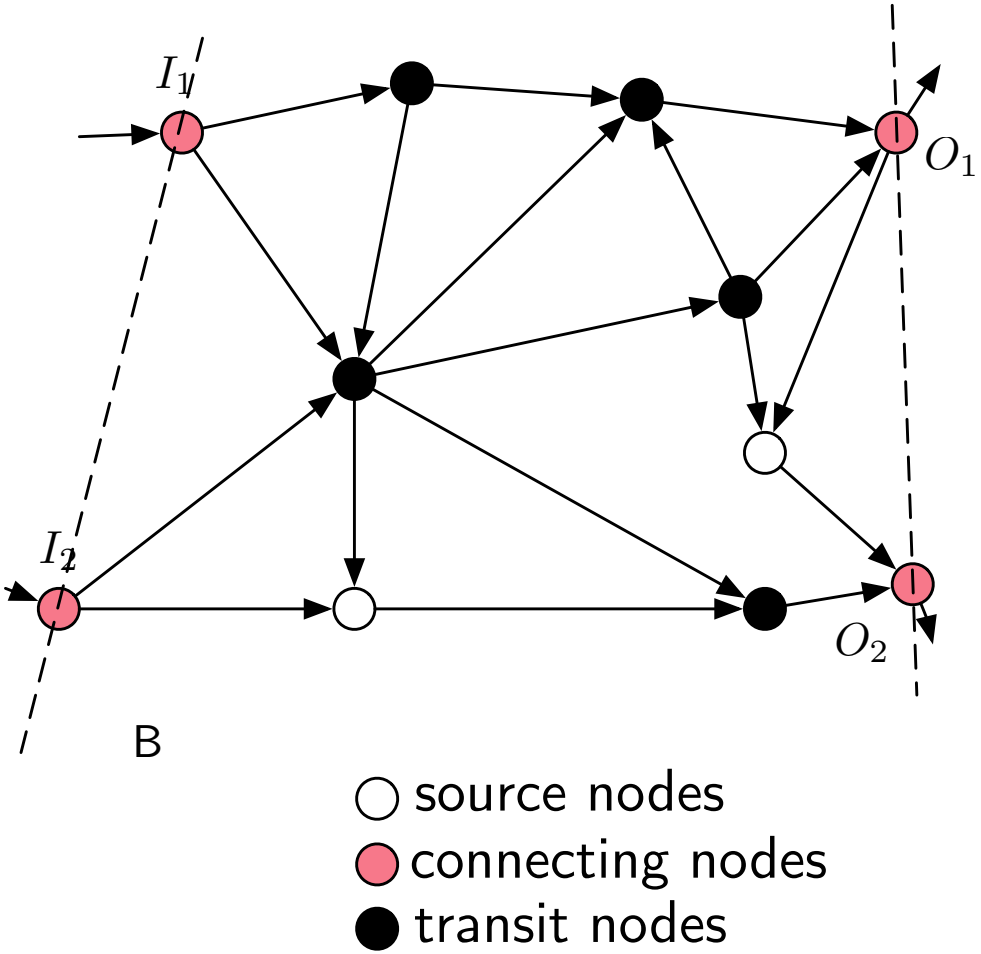

连接出入口的虚拟路段

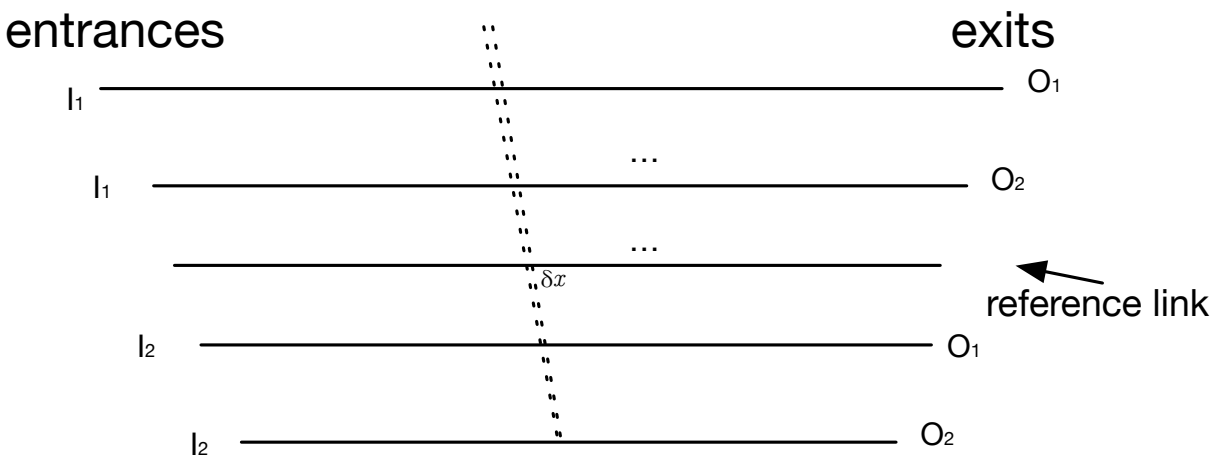

Figure: Path Segments

启发

Figure: 拐角处漂移 (来源: 《极品飞车》游戏截图)

邻域内的交通动态变化

由每个虚拟路段中的守恒律可知 (Leclercq *et al.* 2015):

$$\begin{cases} \partial_t \rho_i + \partial_{x_i}[\rho_i(t, x_i)\tilde{\nu}(t, x)] = 0, \ i = 1, 2, \ldots, n \\ f_i(t, 0) = \psi_i(t, 0), \ i = 1, 2, \ldots, n \end{cases}$$

其中 ψ_i 为从虚拟路段出发的流量 i. $\tilde{\rho}$ 为邻域内所有物理路段的平均密度，n 为虚拟路段数量, $\tilde{\nu}$ 为平均速度

邻域内的交通动态变化（续）

上述偏微分方程组存在等价的单个偏微分方程形式：

$$\begin{cases} \partial_t \tilde{\rho}(t,x) + \frac{1}{n}\partial_x f(t,x) = 0 \\ f_i(t,x_i) = \rho_i(t,x_i)\tilde{\nu}(t,x),\ i = 1,2,\ldots,n \\ f(t,x) = \sum_i f_i(t,x_i),\ f_i(t,0) = \psi_i(t,0),\ i = 1,2,\ldots,n \end{cases}$$

虚拟路段的设计参数

- 虚拟路段的通行能力是多少?
- 虚拟路段的长度该如何选取?

基于最大同时流（MCFP）的通行能力计算

给定一个路网 G = (V,E)，每个路段 $j \in E$ 的最大通行能力为 c_j, 并给定一系列出入口 K, 且该出入口需求为 x_k, 寻找每个（由物理路段构成的）连接各个出入口的路径的流量

$$y_1^1, y_1^2 \ldots, y_k^p \ldots$$

使得

$$\sum_{p \in P_k} y_k^p \geqslant \lambda x_k, \ \forall k \in K$$

并使参数 λ 最大 (Shahrokhi and Matula, 1990). 下标 $p \in P_k$ 表明存在多个路段可连接该出入口

线性规划形式

$$\max \lambda$$

subject to:

$$\text{节点流量守恒} \sum_{u \in V} y_k^p \delta_{p,(u,v)} = \sum_{w \in V} y_k^p \delta_{p,(v,w)} \forall k \in K, \forall v \in V \tag{1}$$

$$\text{路段能力限制} \sum_j y_k^p \delta_{pj} \leqslant c_j, \forall j \in E \tag{2}$$

$$\text{流量与需求成比例} \sum_{p \in P_k} y_k^p \geqslant \lambda x_k, \forall k \in K \tag{3}$$

其中 $\delta_{p,(u,v)}$ 为路径和节点的关联指示函数, δ_{pj} 为路径和路段的关联指示函数.

一个例子

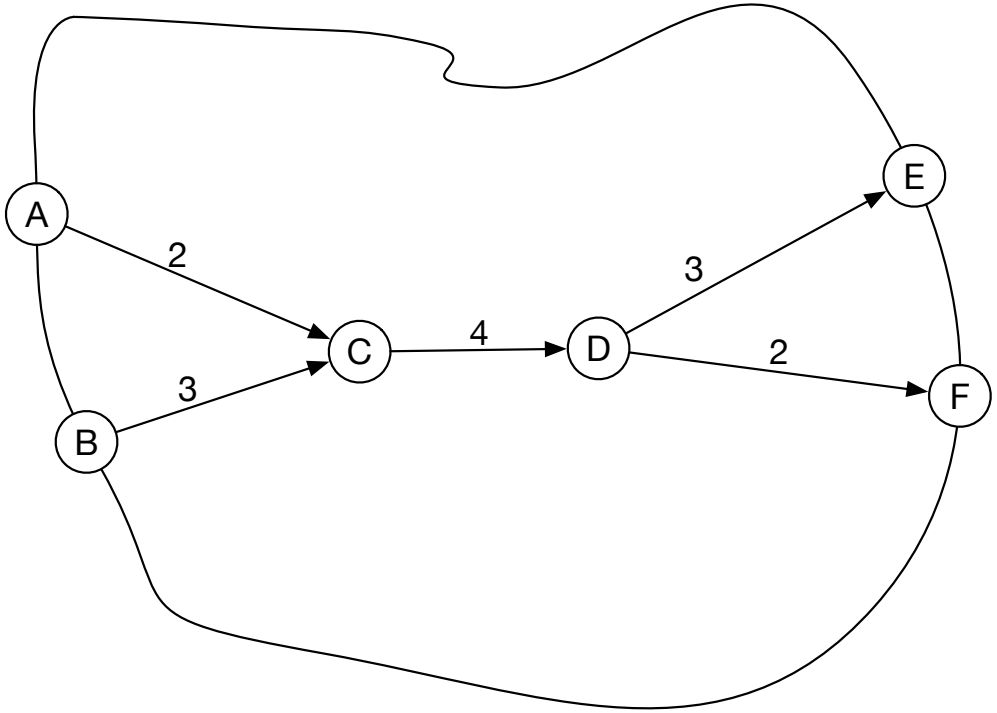

A-F	2
B-E	3

- 最大流: 任何 $f_{A-C-D-F} + f_{B-C-D-E} = 4$ 的组合均满足.
- 最大同时流: $f_{A-C-D-F} = 1.6$，$f_{B-C-D-E} = 2.4$.

剩余通行能力问题

$$\max M\lambda + \sum_k \sum_p y_k^p$$

subject to:

$$\text{节点流量守恒} \sum_{u \in V} y_k^p \delta_{p,(u,v)} = \sum_{w \in V} y_k^p \delta_{p,(v,w)} \forall k \in K, \forall v \in V \tag{4}$$

$$\text{路段能力限制} \sum_j y_k^p \delta_{pj} \leqslant c_j, \forall j \in E \tag{5}$$

$$\text{流量与需求成比例} \sum_{p \in P_k} y_k^p \geqslant \lambda x_k, \forall k \in K \tag{6}$$

其中 M 为一个足够大的正实数.

虚拟路段的长度

我们证明了如下命题：

> 当车辆在邻域内按照动态系统最优或者动态用户均衡的准则行驶，且遵循“先入先出”的规则，则连接出入口的最短路为所有车辆使用的路径

证明: 略，详见于 Ge & Fukuda (2019).

邻域边缘的交通追踪

在 CTM 等宏观交通流模型中，交叉口的运行规则由节点模型描述。此处的模型类似。[MRMP] and [MRDP].

$$\max \sum_{k} \sum_{r \in U(r')} f_{k,r}$$

subject to:

$$0 \leqslant f_{k,r} \leqslant D_{k,r}, \forall k, r \tag{7}$$

$$\sum_{k} \sum_{r \in U(r')} f_{k,r} \leqslant S_{r'} \tag{8}$$

其中 $U(r')$ 为 r' 上游邻域集, $f_{k,r}$ 为邻域 r 中使用路径 k 的流量. $D_{k,r}$ 为路径的需求量. $S_{r'}$ 为下游的供给量.

邻域边缘的交通追踪（续）

$$\max \sum_{k} \sum_{r \in D(r')} f_{k,r}$$

subject to:

$$0 \leqslant f_{k,r} \leqslant S_{k,r}, \forall k, r \tag{9}$$

$$\sum_{k} \sum_{r \in D(p,r')} f_{k,r} \leqslant D_{r'} \tag{10}$$

where $D(r')$ 为 r' 的下游邻域集, $f_{k,r}$ 为邻域 r 中使用路径 k 的流量.. $D_{p,r'}$ 为路径 p 在邻域 r' 的需求量. $S_{k,r}$ 为下游邻域中各路段的供给量.

数值实验

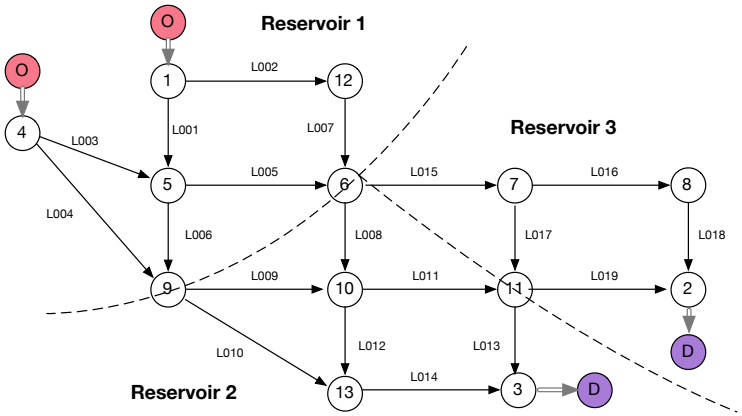
Reservoir 1
Reservoir 2
Reservoir 3
O
D
L001
L002
L003
L004
L005
L006
L007
L008
L009
L010
L011
L012
L013
L014
L015
L016
L017
L018
L019

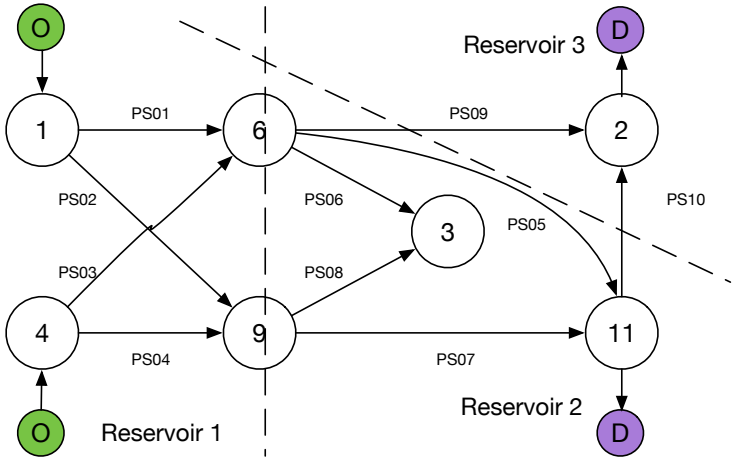
Reservoir 1
Reservoir 2
Reservoir 3
O
D
PS01
PS02
PS03
PS04
PS05
PS06
PS07
PS08
PS09
PS10

低交通需求场景

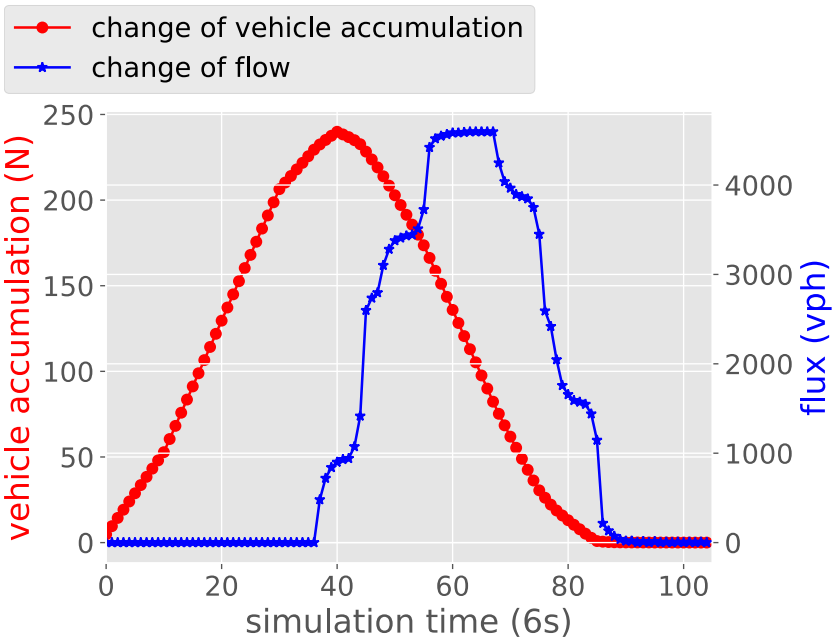
change of vehicle accumulation
change of flow
vehicle accumulation (N)
flux (vph)
simulation time (6s)
0
50
100
150
200
250
0
1000
2000
3000
4000
0
20
40
60
80
100

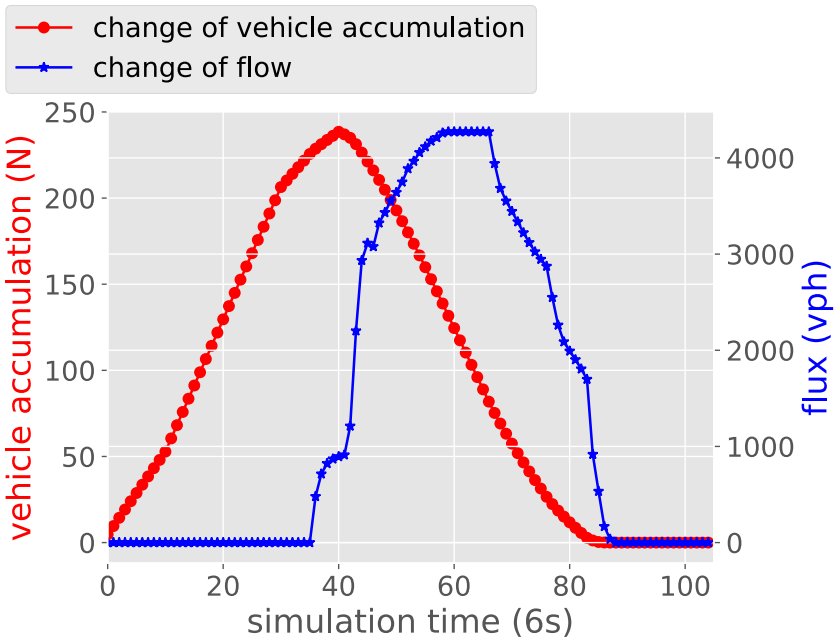
change of vehicle accumulation
change of flow
vehicle accumulation (N)
flux (vph)
simulation time (6s)
0
50
100
150
200
250
0
1000
2000
3000
4000
0
20
40
60
80
100

高交通需求场景

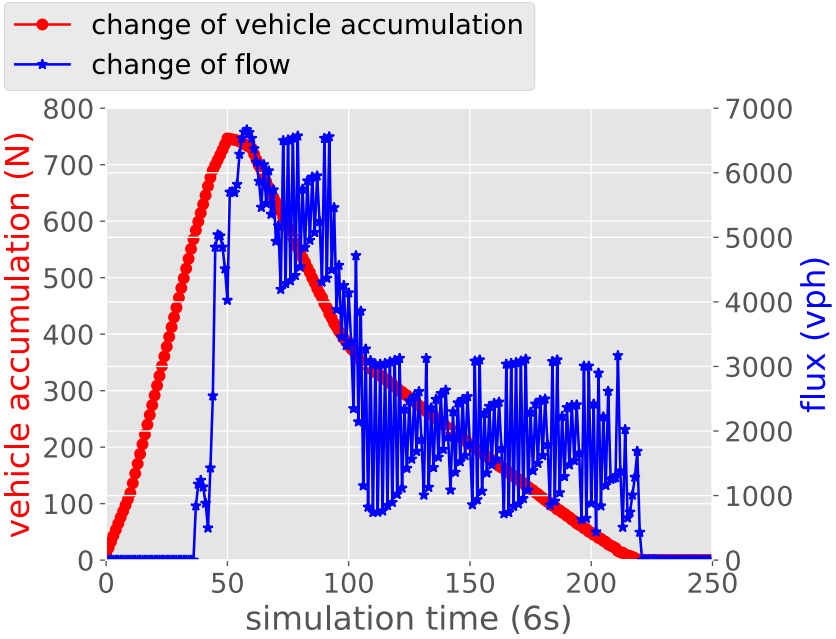
change of vehicle accumulation
change of flow
vehicle accumulation (N)
flux (vph)
simulation time (6s)
0
100
200
300
400
500
600
700
800
1000
2000
3000
4000
5000
6000
7000
0
50
100
150
200
250

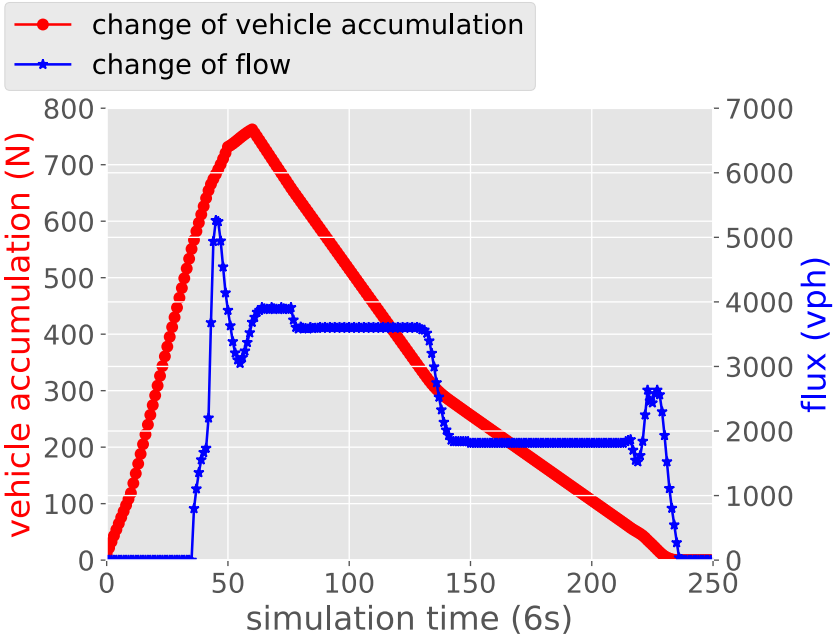
change of vehicle accumulation
change of flow
vehicle accumulation (N)
flux (vph)
simulation time (6s)
0
100
200
300
400
500
600
700
800
1000
2000
3000
4000
5000
6000
7000
0
50
100
150
200
250

计算结果

		CTM	MRDNL	LPKAH
Case I	Running time	28.464	8.895	4.724
no assignment rule	Loading intervals	40	40	40
low demand level	RMSE of travel time (compared with CTM)	–		
	OD 1	0	2.192	62.346
	OD 2	0	21.481	29.144
	OD 3	0	6.442	23.085
	OD 4	0	29.201	95.184
Case II	Running time	284.894	159.492	4.724
DUE assignment	Loading intervals	40	40	40
low demand level	RMSE of travel time (compared with CTM)	–		
	OD 1	0	7.846	54.446
	OD 2	0	14.422	86.815
	OD 3	0	6.422	50.181
	OD 4	0	16.785	92.021
Case III	Running time	607.464	52.833[a]	12.693
DUE assignment	Loading intervals	160	160	160
high demand level	RMSE of travel time (compared with CTM)	–		
	OD 1	0	63.088	139.255
	OD 2	0	45.706	31.876
	OD 3	0	18.874	83.778
	OD 4	0	44.453	41.907
	OD 5	0	51.181	132.535
	OD 6	0	7.054	73.042

讨论

- 本研究基于宏观基本图提出了以邻域为单位的动态网络加载模型
  - 该模型建立在平均密度-平均速度的关系上
  - 提出了计算连接出入口虚拟路段的容量计算方法
  - 基于有限体积法提出了偏微分方程的数值解法
  - 对于路段起始和收尾处不守恒的现象，提出了平衡方案
- 数值实验证明提出的方法在保持高近似精度的同时，能有效降低计算成本
- 更多细节：**Qian Ge** and Daisuke Fukuda. A macroscopic dynamic network loading model for multiple-reservoir system. Transportation Research Part B: Methodological 126 (2019): 502-527.